

Politechnika Warszawska

Wydział Matematyki
i Nauk Informacyjnych

Praca dyplomowa licencjacka

na kierunku Matematyka i Analiza Danych

Wpływ funkcji wag pewności na jakość rekomendacji gier w modelu implicit ALS

Michał Tałałaj

Numer albumu 333092

promotor

dr inż. Robert Małysz

WARSZAWA 2026

Streszczenie

Słowa kluczowe:

Abstract

Keywords:

Spis treści

Streszczenie **3**
Abstract **4**
1. Wstęp **11**
1.1. Motywacja i problem badawczy 11
1.2. Cel, zakres i pytania badawcze 11
1.3. Struktura pracy 11
2. Podstawy teoretyczne systemów rekomendacyjnych **12**
2.1. Zadanie rekomendacji top-N 12
2.2. Explicit feedback, implicit feedback i czas gry 12
2.3. Filtrowanie kolaboratywne i faktoryzacja macierzy 12
2.4. Model implicit ALS 12
2.5. Bayesian Personalized Ranking 12
3. Metryki ewaluacyjne **13**
3.1. Ewaluacja rekomendacji top-K 13
3.2. Metryki trafności rankingu 13
3.3. Metryki pokrycia katalogu, popularności i różnorodności 13
3.4. Ograniczenia porównywania metryk rankingowych 13
4. Przegląd literatury **14**
4.1. Modele dla danych implicit feedback 14
4.2. Systemy rekomendacyjne dla gier i danych Steam 14
4.3. Wykorzystanie czasu gry w literaturze 14
4.4. Problemy reprodukowalności i porównywalności wyników 14
4.5. Podsumowanie roli literatury w pracy 14
5. Dane i analiza eksploracyjna **15**
5.1. Źródło i struktura danych 15
5.2. Dane jako niejawna informacja zwrotna (implicit feedback) 15
5.3. Podstawowe statystyki surowego zbioru 15
5.4. Wpływ przygotowania danych na strukturę zbioru 16
5.5. Rozkład czasu gry i interakcje z zerowym czasem gry 16
5.6. Aktywność użytkowników i popularność gier 17
5.6.1. Aktywność użytkowników 17
5.6.2. Popularność gier 17
5.7. Wnioski z analizy eksploracyjnej 19
6. Metodologia eksperymentalna **21**
6.1. Przygotowanie danych 21
6.2. Porównywane modele 21
6.3. Strojenie hiperparametrów 22

6.4. Finalna ewaluacja testowa . . . 22
6.5. Analiza wrażliwości na α i β . . . 23
6.6. Ograniczenia metodologii . . . 23
7. Wyniki eksperymentów . . . 24
7.1. Wyniki strojenia hiperparametrów . . . 24
7.2. Analiza funkcji wag pewności . . . 25
7.3. Wyniki finalne wariantów ALS . . . 25
7.4. Porównanie z modelami odniesienia . . . 25
7.5. Trafność, pokrycie katalogu i obciążenie popularnością . . . 25
7.6. Stabilność wyników, testy statystyczne i analiza wrażliwości . . . 25
8. Dyskusja i odniesienie do literatury . . . 26
8.1. Interpretacja roli czasu gry . . . 26
8.2. Znaczenie przesunięcia β . . . 26
8.3. Znaczenie interakcji z zerowym i niskim czasem gry . . . 26
8.4. Porównanie ALS z modelami odniesienia . . . 26
8.5. Odniesienie do literatury i próby replikacji . . . 26
8.6. Ograniczenia pracy . . . 26
9. Wnioski . . . 27
9.1. Podsumowanie eksperymentów . . . 27
9.2. Odpowiedź na pytania badawcze . . . 27
9.3. Najważniejsze wnioski praktyczne i metodologiczne . . . 27
9.4. Kierunki dalszych badań . . . 27
Bibliografia . . . 28
Wykaz symboli i skrótów . . . 29
Spis rysunków . . . 29
Spis tabel . . . 30
Załączniki . . . 32
A. Dodatkowe tabele wyników . . . 33
B. Dodatkowe wykresy . . . 34
C. Struktura plików projektu i reprodukowalność . . . 35

1. Wstęp

1.1. Motywacja i problem badawczy

1.2. Cel, zakres i pytania badawcze

1.3. Struktura pracy

2. Podstawy teoretyczne systemów rekomendacyjnych

2.1. Zadanie rekomendacji top-N

2.2. Explicit feedback, implicit feedback i czas gry

2.3. Filtrowanie kolaboratywne i faktoryzacja macierzy

2.4. Model implicit ALS

2.5. Bayesian Personalized Ranking

3. Metryki ewaluacyjne

3.1. Ewaluacja rekomendacji top-K

3.2. Metryki trafności rankingu

3.3. Metryki pokrycia katalogu, popularności i różnorodności

3.4. Ograniczenia porównywania metryk rankingowych

4. Przegląd literatury

4.1. Modele dla danych implicit feedback

4.2. Systemy rekomendacyjne dla gier i danych Steam

4.3. Wykorzystanie czasu gry w literaturze

4.4. Problemy reprodukowalności i porównywalności wyników

4.5. Podsumowanie roli literatury w pracy

5. Dane i analiza eksploracyjna

5.1. Źródło i struktura danych

Dane wykorzystane w pracy pochodzą z publicznie dostępnej kolekcji zbiorów danych zebranych przez zespół Juliana McAuleya [5] z Uniwersytetu Kalifornijskiego w San Diego w celu budowy systemów rekomendacyjnych i personalizacji. W szczególności wykorzystano podzbiór danych zawierający biblioteki użytkowników platformy Steam sprzedającej gry komputerowe.

Źródłowe dane miały postać pliku JSON, w którym każdy rekord opisywał bibliotekę jednego użytkownika, identyfikowanego przez zmienną `user_id`. Dla każdego użytkownika dostępna była lista przypisanych do niego gier wraz z identyfikatorem gry (`item_id`), nazwą (`item_name`) oraz łącznym czasem rozgrywki (`playtime_forever`) w minutach.

Dane wejściowe zostały przekształcone do postaci ramki danych, w której pojedynczy wiersz odpowiada unikalnej parze użytkownik-gra, a następnie do postaci rzadkiej macierzy, której wiersze odpowiadają poszczególnym klientom, kolumny produktom, a wartości dlugości interakcji miedzy poszczególną parą. Jest to standardowa struktura danych w stosowanej w pracy bibliotece systemów rekomendacyjnych.

5.2. Dane jako niejawna informacja zwrotna (implicit feedback)

Wykorzystane dane nie zawierają jawnych ocen przypisanych przez użytkowników, takich jak wartości liczbowe lub gwiazdki. Jedyne sygnały behawioralne informujące o relacji konsumenta z danym produktem jest jego obecność w bibliotece oraz całkowity czas trwania interakcji. Zatem rekomendacje będą oparte na zmiennej `playtime_forever`, która pełni rolę miary intensywności relacji między danym użytkownikiem i produktem. Z tego powodu jest to problem rekomendacji na podstawie niejawnej informacji (implicit feedback). Warto podkreślić, że jest to silnie zaszumiony sygnał i jego wartość nie odzwierciedla proporcjonalnie zainteresowania danym tytułem. Stanowi to motywację do badania wpływu przekształceń tej zmiennej na jakość rekomendacji.

5.3. Podstawowe statystyki surowego zbioru

Przed filtracją analizowany zbiór zawierał 5 153 209 interakcji, obejmujących 70 912 użytkowników oraz 10 978 gier. Wynika stąd, że obserwowana macierz użytkownik-gra była bardzo rzadka: jej gęstość wynosiła około 0,00662, co znaczy, że zaobserwowane zostało zaledwie 0,662% wszystkich możliwych interakcji w macierzy. Niska gęstość macierzy jest powszechna w dziedzinie systemów rekomendacyjnych, ponieważ przeciętny konsument wybierze zaledwie kilka produktów z katalogu zawierającego tysiące lub miliony rekordów.

Tabela 5.1: Podstawowe statystyki surowego zbioru danych

Statystyka	Wartość
Liczba interakcji użytkownik-gra	5 153 209
Liczba użytkowników	70 912
Liczba gier	10 978
Gęstość macierzy	0,00662

5.4. Wpływ przygotowania danych na strukturę zbioru

Przed treningiem i ewaluacją modeli dane zostały poddane filtracji. Szczegółowy opis i uzasadnienie tych decyzji przedstawiono w rozdziale dotyczącym metodologii eksperymentalnej. W tym podrozdziale omówiono jedynie ich wpływ na rozmiar oraz strukturę finalnego zbioru.

Tabela 5.2: Wpływ kolejnych etapów przygotowania danych na rozmiar zbioru

Etap	Interakcje	Użytkownicy	Gry
Dane surowe	5 153 209	70 912	10 978
Po filtracji gier	5 149 512	70 912	9 198
Po filtracji użytkowników	5 132 610	62 944	9 198

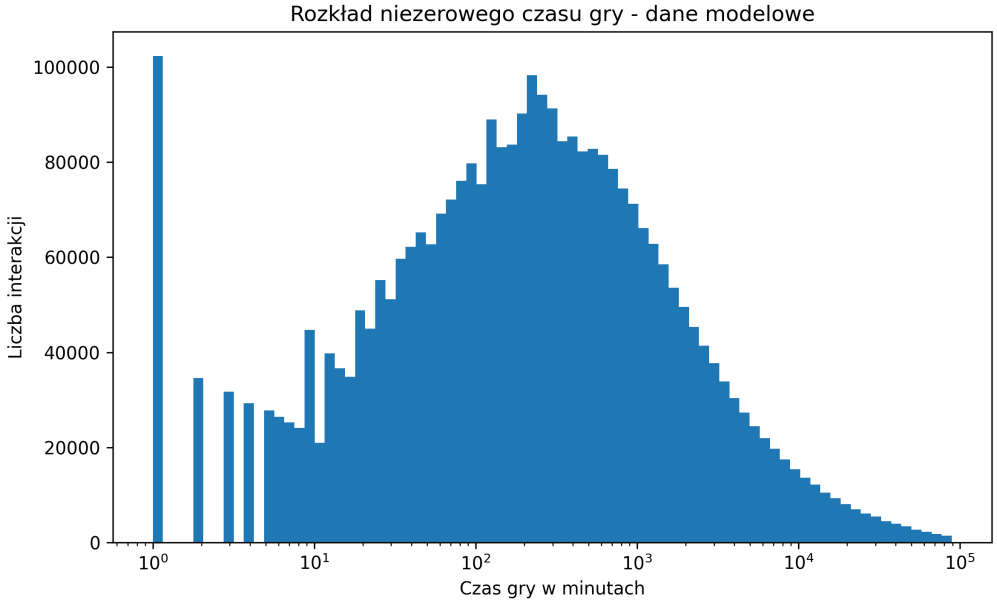
Usunięto 20 599 interakcji, co odpowiada około 0,40% początkowego zbioru. Tymczasem liczba użytkowników zmniejszyła się o 7 968, czyli o 11,24%, a liczba gier o 1 780, czyli o 16,21%. Świadczy to o tym, że przygotowanie danych usunęło przede wszystkim niepopularne gry i mało aktywnych użytkowników, zachowując niemal cały zasób informacji o obserwowanych interakcjach. Gęstość macierzy użytkownik-gra wzrosła z 0,00662 do około 0,00887, jednak nadal pozostała bardzo niska. Zatem zbiór po przygotowaniu nadal ma charakter rzadkich danych rekomendacyjnych, ale jest mniej obciążony przypadkami o małej liczbie interakcji.

5.5. Rozkład czasu gry i interakcje z zerowym czasem gry

Istotną cechą analizowanego zbioru jest występowanie interakcji, dla których wartość zmiennej `playtime_forever` wynosi zero. Oznacza to, że dana gra została zakupiona przez użytkownika, ale nie odnotowano żadnego czasu rozgrywki. Interakcje z zerowym czasem gry stanowiły 36,25% wszystkich obserwacji. Usunięcie ich z analizy zmieniłoby definicję problemu, model uczyłby się wyłącznie na podstawie gier faktycznie uruchomionych, pomijając znaczną liczbę pozytywnych obserwacji. Ponieważ sama obecność gry w bibliotece jest sygnałem behawioralnym świadczącym o zainteresowaniu produktem. w niniejszej pracy obserwacje z `playtime_forever = 0` zostały zachowane jako poprawne interakcje użytkownik-gra.

Dla interakcji z dodatnim czasem gry rozkład zmiennej `playtime_forever` jest silnie prawostronnie skośny. Większość obserwacji koncentruje się przy stosunkowo niskich wartościach, a duże czasy rozgrywki tworzą długi ogon. Na rysunku 5.1 przedstawiono histogram

dodatnich wartości czasu gry w skali logarytmicznej.



Rysunek 5.1: Rozkład dodatniego czasu gry w skali logarytmicznej w przygotowanym zbiorze

Skośność rozkładu czasu gry uzasadnia użycie funkcji wag pewności o spowolnionym wzroście. Liniowe potraktowanie zmiennej `playtime_forever` nadawałoby bardzo dużą wagę skrajnym obserwacjom, przez co mogłoby zaburzać proces uczenia modelu. Natomiast sam fakt obecności gry w bibliotece pozostaje istotną informacją nawet wtedy, gdy czas gry jest równy zero. Z tego powodu szczególnie istotne są funkcje, które pozwalają nadać obserwacjom z `playtime_forever = 0` zwiększony poziom bazowej pewności i jednocześnie spowalniają przyrost wagi pewności dla rosnących wartości czasu gry.

5.6. Aktywność użytkowników i popularność gier

5.6.1. Aktywność użytkowników

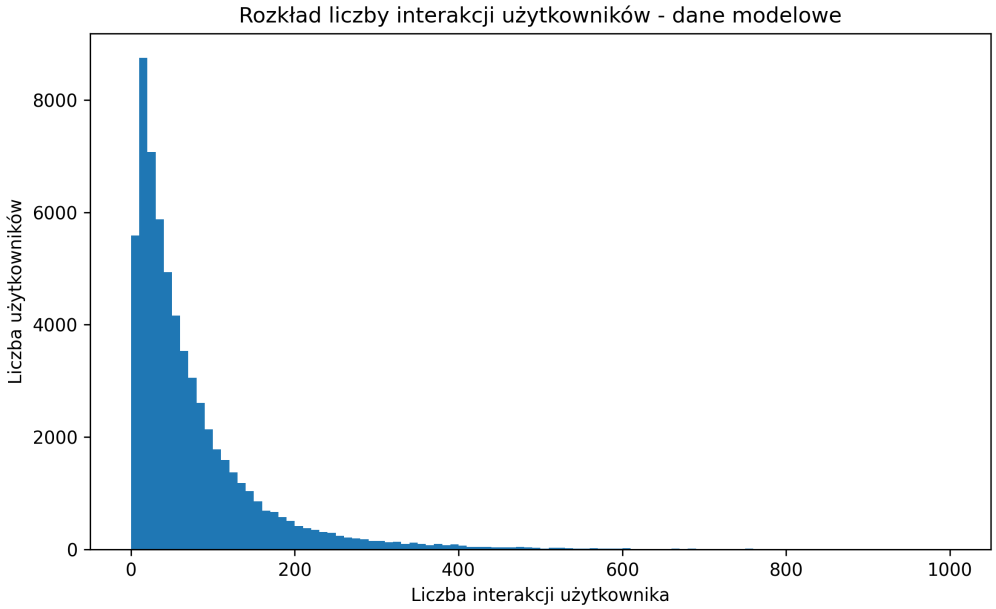
Rozkład liczby interakcji przypadających na użytkownika jest prawostronnie skośny. Na rysunku 5.2 przedstawiono histogram liczby interakcji przypadających na użytkownika. Widoczne skupienie przy niskich wartościach oraz długi ogon pokazują, że zbiór łączy dużą liczbę użytkowników o umiarkowanej aktywności z niewielką grupą kont posiadających bardzo rozbudowane biblioteki. W przygotowanym zbiorze średnia liczba interakcji na użytkownika wynosiła 81,54, podczas gdy mediana była równa 48.

5.6.2. Popularność gier

Jeszcze silniejszą nierównomierność widać po stronie gier. Mediana liczby interakcji przypadających na grę wynosiła 71, podczas gdy średnia była równa 558,01. Wynika stąd, że większość gier występowała w bibliotekach stosunkowo małej liczby użytkowników, natomiast niewielka grupa najpopularniejszych tytułów odpowiadała za bardzo dużą część wszystkich interakcji.

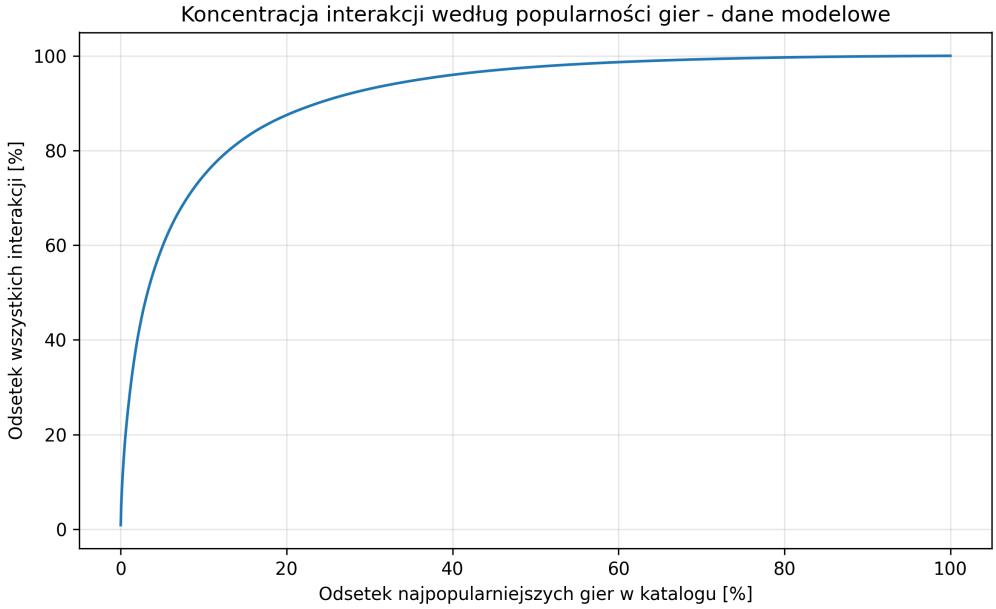
Tabela 5.3: Rozkład liczby interakcji użytkowników i popularności gier w przygotowanym zbiorze

Statystyka	Interakcje użytkownika	Interakcje gry
Średnia	81,54	558,01
Mediana	48	71
95. percentyl	251	2 515,05
99. percentyl	518,57	8 811,84
Maksimum	7 337	45 699



Rysunek 5.2: Rozkład liczby interakcji przypadających na użytkownika w przygotowanym zbiorze danych

Koncentrację popularności przedstawiono na rysunku 5.3. Najpopularniejszy 1% gier odpowiadał za około 27,16% wszystkich interakcji, najpopularniejsze 5% za 59,55%, a najpopularniejsze 10% za 74,71%.



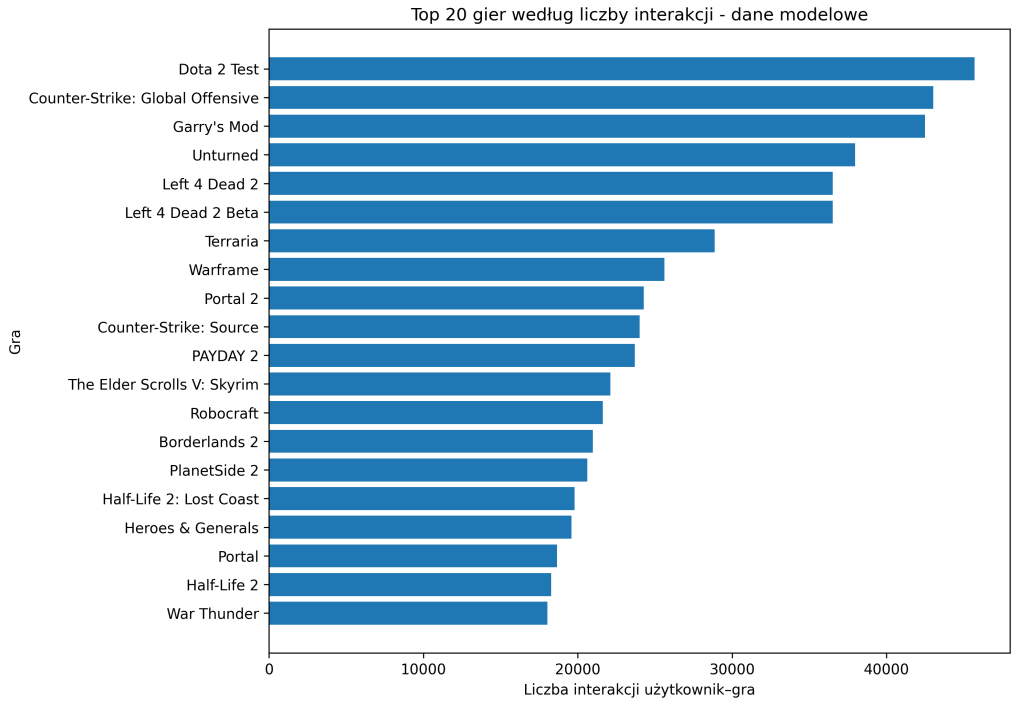
Rysunek 5.3: Koncentracja interakcji według popularności gier w przygotowanym zbiorze danych

Dodatkową ilustracją tej nierównomierności jest zestawienie najpopularniejszych gier przedstawione na rysunku 5.4. Wśród tytułów o największej liczbie interakcji znajdują się przede wszystkim bardzo popularne gry wieloosobowe oraz darmowe produkcje obecne w bibliotekach dużej liczby użytkowników. Obecność takich pozycji pokazuje, że prosty model oparty wyłącznie na popularności mógłby generować pozornie atrakcyjne rekomendacje, ale jednocześnie silnie ograniczałby różnorodność katalogu.

Zaobserwowana koncentracja popularności ma znaczenie dla interpretacji późniejszych wyników eksperymentalnych. Modele rekomendacyjne mogą osiągać dobrą trafność, często rekomendując najpopularniejsze tytuły, ale takie zachowanie prowadzi do niskiego pokrycia katalogu i silnego obciążenia rekomendacji popularnością. Z tego powodu w dalszej części pracy, obok metryk trafności rankingowej, analizowane są również miary pokrycia katalogu oraz popularności rekomendowanych gier.

5.7. Wnioski z analizy eksploracyjnej

Najważniejsze cechy analizowanego zbioru danych, które bezpośrednio wpłynęły na przyjętą metodologię badawczą, to silnie prawostronnie skośny rozkład czasu gry użytkowników oraz wyraźna koncentracja popularności gier. Rozkład zmiennej `playtime_forever` charakteryzuje się długim ogonem, co wymaga odpowiedniego przekształcenia tej zmiennej w wagę pewności wykorzystywaną w modelu. Z kolei nierównomierny rozkład popularności gier oznacza, że niewielka część katalogu generuje znaczną część interakcji, co należy uwzględnienić w ocenie jakości rekomendacji poprzez analizę miar pokrycia katalogu oraz obciążenia popularnością.



Rysunek 5.4: Dwadzieścia najpopularniejszych gier według liczby interakcji w przygotowanym zbiorze danych

Kolejnym istotnym aspektem jest rola obserwacji z wartością `playtime_forever = 0`, które mimo braku aktywności stanowią ważny sygnał behawioralny i zostały zachowane w procesie uczenia modeli. Wymagają one przekształcenia w wagę pewności, które nada im zwiększony poziom bazowy. Co w połączeniu z odpowiednim spowolnieniem przyrostu wagi dla rosnących wartości czasu gry pozwoli na lepsze wykorzystanie informacji zawartych w danych wejściowych.

6. Metodologia eksperymentalna

6.1. Przygotowanie danych

Przed właściwym procesem trenowania modeli dane zostały poddane wstępnej obróbce. W analizowanym zbiorze nie występowały braki danych, więc ich filtracja nie była konieczna. Ze względu na obecność wartości odstających zmiennej `playtime_forever` zdecydowano się na ograniczenie jej wartości do 120000 minut, co odpowiada 2000 godzinom, oraz w przybliżeniu 99,97 percentylowi w zbiorze danych. Obserwacje powyżej tej granicy zostały zastąpione wartością 120000. Założono, że wartości powyżej tej granicy nie niosą istotnej informacji o preferencjach graczy, a jedynie mogą zaburzyć proces trenowania modeli.

Usunięto również gry przypisane do mniej niż 5 użytkowników oraz użytkowników posiadających w swojej bibliotece mniej niż 5 gier. Miało to na celu zmiejszenia wpływu zimnego startu na wyniki modeli oraz możliwość późniejszego podziału danych na zbiory treningowy, walidacyjny i testowy, w sposób zapewniający, że każdy użytkownik pojawi się w każdym z tych zbiorów.

Zbiór po filtracji został podzielony na zbiory: treningowy, walidacyjny i testowy. Dla każdego użytkownika do zbioru testowego przypisano liczbę interakcji równą $\lceil 0{,}1 \cdot n_u \rceil$, gdzie n_u oznacza liczbę interakcji danego użytkownika. Zastosowano zaokrąglenie w górę, aby zapewnić, że każdy użytkownik będzie miał co najmniej jedną interakcję w zbiorze testowym. Podział został przeprowadzony w sposób losowy ze względu na brak inforamcji o datach przypisania produktów do bibliotek użytkowników. Pozostały zbiór został analogicznie podzielony na zbiór treningowy i walidacyjny. W celu zachowania reprodukowalności wyników, na każdym etapie podziału zostało ustalone ziarno generatora liczb pseudolosowych.

6.2. Porównywane modele

Porównano sześć modeli rekomendacyjnych, w tym cztery modele implicit ALS z różnymi funkcjami wag pewności (confidence), model Bayesian Personalized Ranking (BPR) zawarte w bibliotece implicit `implicit` [3] oraz model popularnościowy jako punkt odniesienia. Zastosowane funkcje wag pewności w modelach implicit ALS to:

- $c_{ui} = 1 + \alpha r_{ui}$,
- $c_{ui} = 1 + \alpha \log(1 + r_{ui})$,
- $c_{ui} = 1 + \alpha \frac{\log(1+r_{ui})}{1+\log(1+r_{ui})}$,
- $c_{ui} = 1 + \alpha(\log(1 + r_{ui}) + \beta)$,

gdzie r_{ui} oznacza zmienną `playtime_forever` dla użytkownika u i gry i, a α jest domyślnym hiperparametrem w modelach implicit ALS. Dwie pierwsze funkcje wag pewności zostały zaproponowane w pracy [4], natomiast kolejne zostały utworzone na podstawie wyników poprzednich modeli i analizy rozkładu zmiennej `playtime_forever` w zbiorze danych. W szczególności funkcja $c_{ui} = 1+\alpha(\log(1+r_{ui})+\beta)$ została zaproponowana w celu zmniejszenia wpływu szumu wynikającego z dużej liczby obserwacji o niskiej wartości zmiennej `playtime_forever`, które ze względu na własności logarytmu mają stosunkowo wysoką wartość w funkcjach wag pewności, a nie są realnym odzwierciedleniem preferencji użytkowników. Dodatkowo przesunięcie β pozwala nadać obserwacjom z `playtime_forever = 0` wagę większą niż 1, co miało na celu wyrazić zainteresowanie użytkownika grą, wynikające z jej zakupu, mimo braku czasu spędzonego w grze. Aby uniknąć arbitralnego wyboru wartości β, w eksperymencie przeprowadzono strojenie tego hiperparametru.

6.3. Strojenie hiperparametrów

Proces strojenia hiperparametrów został przeprowadzony na podstawie zbioru walidacyjnego. Celem była optymalizacja NDCG@10 dla każdego z modeli. Procedura miała charakter dwuetapowy. Najpierw przeprowadzono szeroki grid search dla wszystkich modeli, aby znaleźć przybliżony zakres najlepszych wartości hiperparametrów, a następnie dokładnie przeszukano ten zakres za pomocą algorytmu Optuna [1]. W przypadku modeli implicit ALS strojenie obejmowało hiperparametry α i β odpowiedzialne za wagę pewności, liczbę wymiarów latentnych f oraz siłę regularizacji λ. Liczba iteracji algorytmu ALS została ustalona na 30, ze względu na brak istotnej poprawy wyników przy większej liczbie iteracji podczas wstępnego przeszukiwania siatkowego. Natomiast dla modelu BPR strojenie obejmowało f, λ, liczbę iteracji oraz długość kroku. W przypadku modelu popularnościowego nie przeprowadzano strojenia ze względu na brak hiperparametrów. Dla każdego z optymalizowanych modeli przeprowadzono 150 prób algorytmu Optuna, a w przypadku gdy znaleziona optymalna kombinacja hiperparametrów leżała na granicy przeszukiwanego przedziału, procedurę powtarzano z opowiednio przesuniętym zakresem. Każdy etap przeprowadzono z ustalonym ziarnem generatora liczb pseudolosowych, aby zapewnić reprodukowalność wyników.

6.4. Finalna ewaluacja testowa

Po wybraniu optymalnych wartości hiperparametrów dla każdego z modeli policzono odchylenie standardowe metryk dla 5 podziałów na zbiór treningowy i walidacyjny w celu sprawdzenia stabilności modeli ze względu na losowość podziału danych. Następnie zostały one ponownie wytrenowane na połączonym zbiorze treningowym i walidacyjnym. Po czym poddano je ewaluacji na podstawie metryk precyzji (precision), czułości (recall) i NDCG, będącymi metrykami trafności rekomendacji, a także metryki pokrycia (coverage), różnorodności (diversity) i różnicy w popularności rekomendacji (delta GAP). Każda z metryk została obliczona dla listy rekomendacji o długości 10, a następnie uśredniona po wszystkich użytkownikach. Ewaluację powtórzono 5 razy z różnym ziarnem losowym modelu, a wyniki uśredniono oraz obliczono odchylenie standardowe. Dodatkowo metryka NDCG@10 została wyznaczona dla indywidualnie dla każdego użytkownika, co pozwoliło na przepro-

wadzenie testu Wilcoxona dla par obserwacji w celu sprawdzenia istotności statystycznej różnic jakości rekomendacji między modelami.

6.5. Analiza wrażliwości na α i β

Ze względu na szczególnie zainteresowanie wpływem wag pewności na jakość rekomendacji, przeprowadzono dodatkową analizę parametru odpowiedzialnego za ich skalowanie, czyli α. W tym celu dla każdej funkcji pewności w modelach implicit ALS przeprowadzono eksperymenty, w których obliczono NDCG@10 dla 25 wartości tego hiperparametru w równych odstępach na siatce logarytmicznej wokół optymalnej wartości znalezionej w procesie strojenia. Analogiczny eksperyment przeprowadzono dla 40 wartości parametru β w funkcji $c_{ui} = 1+\alpha(\log(1+r_{ui})+\beta)$, w celu sprawdzenia wrażliwości modelu na jego zmianę. Utworzono również dodatkowe wykresy przedstawiające zależność funkcji pewności od zmiennej `playtime_forever` oraz wyznaczono jej efektywny zakres dla poszczególnych modeli Implicit ALS. Pozwoliło to na lepsze zrozumienie, w jaki sposób zastosowane przekształcenia wpływają na proces uczenia modeli.

6.6. Ograniczenia metodologii

Prezentowane badanie posiada pewne ograniczenia, które mogą wpływać na interpretację wyników. Przede wszystkim eksperyment został przeprowadzony na jednym zbiorze danych, by uzyskać w pełni reprezentatywne wyniki, należałoby powtórzyć go na innych zbiorach danych. W zbiorze nie pojawiła się informacja o dacie przypisania poszczególnych gier do bibliotek użytkowników, co uniemożliwiło przeprowadzenie podziału danych w sposób chronologiczny oraz uwzględnienia zmiany preferencji użytkowników w czasie. Ponadto ewaluacja została przeprowadzona na wszystkich graczach bez podziału na grupy ze względu na liczbę interakcji, co mogłoby ujawnić różnice w jakości rekomendacji dla użytkowników o różnym poziomie aktywności. Dodatkowo ewaluacja została przeprowadzona w sposób offline, a nie w sposób testu A/B. Na koniec warto uwzględnić, że ze względu na czasochłonne obliczenia oraz ilość trenowanych modeli podczas analizy wrażliwości na α i β pozostałe hiperparametry pozostały na stałym poziomie, który wybrano na podstawie modelu z największym NDCG@10 w wybranej rodzinie.

7. Wyniki eksperymentów

7.1. Wyniki strojenia hiperparametrów

Wyniki strojenia hiperparametrów dla każdego z modeli implicit ALS zostały przedstawione w tabeli 7.1. Tak jak wspomniano w metodologii parametr odpowiadający za ilość iteracji jest równy 30 w każdym z modeli.

Tabela 7.1: Najlepsze hiperparametry wariantów ALS wybrane na zbiorze walidacyjnym

Wariant	Czynniki	α	β	Regularyzacja	NDCG@10
Liniowa	80	$9.948 \cdot 10^{-7}$	-	0.003588	0.249
Logarytmiczna	24	0.000571	-	0.130920	0.261
Logarytmiczna z saturacją	24	0.024390	-	0.169714	0.261
Logarytmiczna z przesunięciem β	48	0.389185	108.284	0.010565	0.275

Źródło: opracowanie własne na podstawie wyników Optuny.

Warto zwrócić szczególną uwagę na niskie wartości parametru α odpowiadającego za skalowanie wagi pozytywnych interakcji. Jako standardową wartość tego hiperparametru zwykle przyjmuje się 1 [2, 3], a przeszukanie przeprowadza wsród większych wartości w celu zróżnicowania dlugich interakcji od ich braku. Konsekwencją tego jest bardzo małe wykorzystanie potencjalnych informacji o preferencjach zawartych w długości czasu gry. Taki wynik był spodziewany w przypadku liniowego przekształcenia ze względu na przypisywanie ogromnych wag pewności dla obserwacji z długiego ogona. Klasycznym rozwiązaniem tego problemu jest zastosowanie logarytmu, jednak pomimo poprawy NDCG@10 α nadal pozostała mała. Z tego powodu zdecydowano się na zastosowanie przekształcenia $c_{ui} = 1 + \alpha \frac{\log(1+r_{ui})}{1+\log(1+r_{ui})}$ ograniczającego wartości zmiennej przed skalowaniem do przedziału $[0, 1)$. Nie miało to jednak znaczącego wpływu na metrykę NDCG@10 na zbiorze walidacyjnym, a dodatkowe eskperymenty pokazały marginalność różnic między tymi modelami. Wyniki poprzednich eksperymentów doprowadziły do sformułowania hipotezy, że niskie wartości `playtime_forever` wprowadzały znaczny szum do modeli stosujących logarytmiczne przekształcenia, co w efekcie zmuszało dobór niewielkich α w procesie optymalizacji hiperparametrów. W celu zniwelowania tego zjawiska oraz nadania interakcjom z `playtime_forever = 0` zastosowano $c_{ui} = 1 + \alpha \log(1 + r_{ui} + \beta)$. W procesie optymalizacji β została ustalona na wartość 108,284, co umożliwiło skuteczne różnicowanie siły interakcji, bez ryzyka zdominowania procesu uczenia przez szum informacyjny krótkich sesji bądź przez dużą skalę wartości długich interakcji.

7.2. Analiza funkcji wag pewności

7.3. Wyniki finalne wariantów ALS

7.4. Porównanie z modelami odniesienia

7.5. Trafność, pokrycie katalogu i obciążenie popularnością

7.6. Stabilność wyników, testy statystyczne i analiza wrażliwości

8. Dyskusja i odniesienie do literatury

8.1. Interpretacja roli czasu gry

8.2. Znaczenie przesunięcia β

8.3. Znaczenie interakcji z zerowym i niskim czasem gry

8.4. Porównanie ALS z modelami odniesienia

8.5. Odniesienie do literatury i próby replikacji

8.6. Ograniczenia pracy

9. Wnioski

9.1. Podsumowanie eksperymentów

9.2. Odpowiedź na pytania badawcze

9.3. Najważniejsze wnioski praktyczne i metodologiczne

9.4. Kierunki dalszych badań

Bibliografia

[1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta i Masanori Koyama. „Optuna: A Next-generation Hyperparameter Optimization Framework". W: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, s. 2623–2631. DOI: 10.1145/3292500.3330701.

[2] Apache Spark Project. *Apache Spark Machine Learning Library (MLlib) - Collaborative Filtering*. 2026. URL: https://spark.apache.org/docs/latest/api/python/reference/api/pyspark.ml.recommendation.ALS.html.

[3] Ben Frederickson. *implicit: Fast Python Collaborative Filtering for Implicit Datasets*. GitHub repository. 2022. URL: https://github.com/benfred/implicit.

[4] Yifan Hu, Yehuda Koren i Chris Volinsky. „Collaborative Filtering for Implicit Feedback Datasets". W: *Proceedings of the 8th IEEE International Conference on Data Mining*. 2008, s. 263–272. DOI: 10.1109/ICDM.2008.22.

[5] Julian McAuley i UCSD. *Steam Video Game and Bundle Data*. https://cseweb.ucsd.edu/~jmcauley/datasets.html. Dostęp: 2026-06-03.

Wykaz symboli i skrótów

Spis rysunków

5.1 Rozkład dodatniego czasu gry w skali logarytmicznej w przygotowanym zbiorze 17
5.2 Rozkład liczby interakcji przypadających na użytkownika w przygotowanym zbiorze danych 18
5.3 Koncentracja interakcji według popularności gier w przygotowanym zbiorze danych 19
5.4 Dwadzieścia najpopularniejszych gier według liczby interakcji w przygotowanym zbiorze danych 20

Spis tabel

5.1 Podstawowe statystyki surowego zbioru danych 16
5.2 Wpływ kolejnych etapów przygotowania danych na rozmiar zbioru 16
5.3 Rozkład liczby interakcji użytkowników i popularności gier w przygotowanym zbiorze 18

7.1 Najlepsze hiperparametry wariantów ALS wybrane na zbiorze walidacyjnym 24

Załączniki

A. Dodatkowe tabele wyników

B. Dodatkowe wykresy

C. Struktura plików projektu i reprodukowalność